

Actividad - Métodos supervisados en Inteligencia Artificial

Proyecto: Sistema inteligente para transporte masivo colombiano basado en rutas tipo TransMilenio.

Integrantes: _____ / _____ / _____

Repositorio Git/GitLab: PEGAR_AQUI_EL_LINK_DEL_REPOSITORIO

Video explicativo: PEGAR_AQUI_EL_LINK_DEL_VIDEO

Mapa conceptual: mapa_conceptual_metodos_supervisados.png

1. Introducción

La actividad continúa el proyecto desarrollado anteriormente, donde se planteó un sistema inteligente para encontrar la mejor ruta entre estaciones de un sistema de transporte masivo colombiano. En esa primera fase se trabajó con una base de conocimiento, estaciones como nodos, conexiones como rutas y el algoritmo de Dijkstra para calcular el menor tiempo de desplazamiento. En esta nueva fase se aplica aprendizaje supervisado para predecir el nivel de congestión de una ruta y apoyar la toma de decisiones operativas.

2. Relación con métodos supervisados

Un método supervisado aprende a partir de ejemplos que ya tienen una respuesta conocida. En este caso, cada registro del dataset contiene información de una ruta, como día, horario, número de pasajeros, buses disponibles, lluvia, eventos e incidentes. La respuesta conocida es el campo nivel_congestion, clasificado como Baja, Media o Alta. Con esos ejemplos, el modelo aprende reglas para clasificar nuevos casos.

3. Fuente de datos identificada o desarrollada

Para el proyecto se propone como fuente de datos un histórico de operación del sistema de transporte masivo. Como no se cuenta con una base real entregada por una entidad oficial, se construyó un dataset de muestra llamado dataset_transporte_masivo.csv. Este archivo contiene 180 registros simulados con variables operativas útiles para entrenar un modelo supervisado.

Variable	Descripción
dia_semana	Día en que se presenta el registro.
franja_horaria	Momento del día: madrugada, mañana pico, mediodía, tarde pico o noche.
linea	Zona o línea principal de operación.
pasajeros_estimados	Cantidad aproximada de usuarios en la ruta.
buses_disponibles	Cantidad de buses disponibles para atender la ruta.
lluvia	1 si hay lluvia, 0 si no hay.
evento_cercano	1 si hay evento cercano, 0 si no hay.
incidente_reportado	1 si hay incidente operativo, 0 si no hay.
tiempo_base_min	Tiempo normal estimado de la ruta.

nivel_congestion	Variable objetivo: Baja, Media o Alta.
------------------	--

4. Modelo desarrollado

El modelo seleccionado fue un árbol de decisión, porque permite explicar de forma sencilla cómo se llega a una predicción. Este tipo de modelo crea reglas con condiciones, por ejemplo: si hay muchos pasajeros, pocos buses disponibles, lluvia o incidentes, entonces aumenta la probabilidad de congestión alta.

El procedimiento realizado en Python fue: cargar los datos con pandas, separar variables de entrada y salida, transformar las variables categóricas con OneHotEncoder, dividir los datos en entrenamiento y prueba, entrenar un DecisionTreeClassifier y evaluar el resultado con exactitud, reporte de clasificación y matriz de confusión.

5. Comandos principales en Python

```
# Cargar datos
datos = pd.read_csv("dataset_transporte_masivo.csv")

# Separar entradas y salida
X = datos.drop(columns=[
    "id_registro", "nivel_congestion",
    "recomendacion_operativa", "retraso_estimado_min"
])
y = datos["nivel_congestion"]

# Preprocesamiento y modelo
preprocesamiento = ColumnTransformer([
    ("cat", OneHotEncoder(handle_unknown="ignore"), columnas_categoricas),
    ("num", "passthrough", columnas_numericas)
])
modelo = DecisionTreeClassifier(max_depth=5, random_state=42)

# Entrenar y evaluar
pipeline = Pipeline([
    ("preprocesamiento", preprocesamiento),
    ("modelo", modelo)
])
pipeline.fit(X_entrenamiento, y_entrenamiento)
predicciones = pipeline.predict(X_prueba)
print(accuracy_score(y_prueba, predicciones))
```

6. Resultados obtenidos

El modelo se entrenó con el 75% de los datos y se probó con el 25% restante. La exactitud obtenida fue de **75.56%**. Este resultado indica que el prototipo logra clasificar correctamente la mayoría de los casos del conjunto de prueba.

Matriz de confusion


Valor real	Baja	19	3	0
	Media	1	10	3
	Alta	0	4	5
		Baja	Media	Alta
		Prediccion		

La matriz de confusión muestra la comparación entre las clases reales y las predicciones del modelo. Para un trabajo académico, este resultado permite evidenciar que el componente fue probado y que el modelo genera una salida verificable.

7. Prueba con caso nuevo

Se probó un caso nuevo con un viernes en tarde pico, línea Norte, ruta Portal Norte - Calle 76, 980 pasajeros estimados, 7 buses disponibles, lluvia e incidente reportado. El modelo clasificó el caso como congestión Alta. La recomendación operativa sería activar ruta alterna y control operativo.

8. Mapa conceptual



9. Guion sugerido para el video máximo de 5 minutos

0:00 - 0:40: Presentar el proyecto. Explicar que viene de un sistema inteligente para buscar rutas en transporte masivo usando estaciones, conexiones y Dijkstra.

0:40 - 1:30: Explicar la fuente de datos. Decir que se creó un dataset de muestra con registros de operación: día, franja horaria, línea, estaciones, pasajeros, buses, lluvia, eventos e incidentes.

1:30 - 2:50: Mostrar el código Python. Explicar carga del CSV, separación de X e y, transformación de variables categóricas, división entrenamiento/prueba y entrenamiento del árbol de decisión.

2:50 - 4:10: Mostrar resultados. Explicar la exactitud, la matriz de confusión y el caso nuevo probado.

4:10 - 5:00: Cerrar con la utilidad del proyecto: apoyar decisiones como mantener ruta normal, aumentar buses o activar rutas alternas según el nivel de congestión.

10. Conclusiones

El aprendizaje supervisado permite crear un modelo capaz de aprender a partir de registros históricos y clasificar nuevos casos. En el proyecto de transporte masivo, el árbol de decisión ayuda a predecir si una ruta tendrá congestión baja, media o alta. Aunque el dataset usado es una muestra desarrollada para la actividad, el proceso demuestra cómo se podría trabajar con datos reales de operación para mejorar la planeación del servicio.

11. Bibliografía

Palma Méndez, J. T. (2008). *Inteligencia artificial: métodos, técnicas y aplicaciones*. Madrid: McGraw-Hill España.